

Pipeline de Extracción Documental PDF → Markdown

Documentación Técnica del Sistema de Conversión de FDS

Alan Osorio · Santiago Díaz · Juan Camilo Gallardo

Universidad Sergio Arboleda

Mayo 2026

Documentación del Pipeline PDF → Markdown

Descripción general

El pipeline convierte los PDFs de Fichas de Datos de Seguridad (FDS) a Markdown estructurado, preservando la organización en 16 secciones GHS y la trazabilidad de tablas e imágenes.

Herramientas elegidas

Tarea	Herramienta	Alternativa descartada	Razón de la elección
Extracción de texto y estructura	PyMuPDF (fitz)	Docling, pdfminer	Preserva metadatos de fuentes (tamaño, negrita) para inferir jerarquía
Extracción de tablas	pdfplumber	Camelot, tabulapyp	Robusto en tablas sin bordes explícitos, API simple
OCR de imágenes	Tesseract (spa+eng)	EasyOCR, PaddleOCR	Soporte oficial de español, sin GPU requerida
Detección de secciones	Regex (SECCIÓN \d+)	Heurísticas de formato	Las FDS CORONA siguen la normativa GHS consistentemente

Flujo de procesamiento

PDF	
→ parser.py	Extrae bloques de texto (PyMuPDF)
list_item	Clasifica: heading1/2/3, paragraph,
de página	Criterio: tamaño de fuente vs. mediana
→ sections.py	Detecta "SECCIÓN N:" con regex
_STRICT_RE	Mapea a 16 títulos estándar GHS en
español	Reporta secciones faltantes como
advertencias	
→ tables.py	Extrae tablas con pdfplumber
col)	Convierte a formato Markdown (col
col)	Genera fila de separadores (---
---)	
→ ocr.py	Extrae imágenes con
page.get_images(full=True)	Convierte a PNG en memoria
	Ejecuta Tesseract (lang="spa+eng")
	Detecta sección de contexto desde
texto de página	
a esta figura	Genera nota: "La información asociada
	se encuentra en la
Sección N: Título."	
→ md_writer.py	Ensambla el .md final por orden de
página	
	Escribe encabezados ## SECCIÓN N:
Título	
	Intercala tablas y notas OCR en
posición correcta	Guarda en output/markdown/

Preservación de las 16 secciones GHS

El módulo `sections.py` define `GHS_SECTIONS` (dict 1..16) con los títulos estándar en español, y usa `_STRICT_RE = re.compile(r"SECCI[OÓ]N\s+(\d+)", re.IGNORECASE)` para detectar encabezados de sección en el texto extraído.

Si una sección no se detecta en el documento, se registra como advertencia y el documento continúa procesándose. En los 17 FDS de CORONA, las 16 secciones se detectaron en todos los documentos.

Tratamiento de tablas

- `pdfplumber` extrae tablas con sus celdas y detecta automáticamente filas de encabezado.
- Las celdas `None` se sustituyen por cadena vacía para mantener alineación Markdown.
- El chunker posterior trata cada tabla como **unidad atómica** (no se divide entre chunks).

Tratamiento de imágenes y OCR

1. `PyMuPDF` extrae imágenes de cada página (`page.get_images(full=True)`).
2. Cada imagen se renderiza a PNG en memoria (sin escritura a disco en esta etapa).
3. Tesseract procesa el PNG con `lang="spa+eng"` y retorna el texto extraído.
4. Se determina la sección de contexto buscando el último encabezado `## SECCIÓN N:` antes de la posición de la imagen en la página.
5. Se genera la nota de trazabilidad y se guarda la imagen en `output/images/`.

Resultado del pipeline en CORONA

- **17/17 PDFs** convertidos exitosamente.
- **626 imágenes** extraídas con notas de trazabilidad.

- **16/16 secciones** detectadas en todos los documentos.
- Tiempo de ejecución: ~3-5 minutos en CPU local.

Limitaciones conocidas

Ver docs/errores_extraccion.md para el registro completo de anomalías detectadas.